

Referencial de Inteligência Computacional

Colab **(Sandbox)** **do** **Fernando:**
<https://colab.research.google.com/drive/1S7GUV-vkBNNFRoBolj7UK2Y6CKBxPN9c?usp=sharing>
Github: <https://github.com/igorzeck/ICD005-Busca-Heur-stica-Data-Mining>

MINERAÇÃO DE DADOS

Em qualquer área de atuação, a tomada de decisões é um processo extremamente sensível, já que qualquer mudança, por menor que pareça, pode reverter totalmente um cenário específico, seja para o pior ou para o melhor. A fim de garantir que o melhor aconteça, é importante que as decisões sejam baseadas em informações válidas e relevantes e essas, por sua vez, são obtidas através de um processo conhecido como *mineração de dados*. Portanto, feito de maneira organizada e com as fontes certas, a mineração de dados é uma etapa essencial na vida de um negócio, especialmente quando se leva em conta a competitividade instaurada em via da enorme quantidade de dados produzidos por segundo. Aqueles que sabem extrair, explorar e analisar os dados certos, de forma rápida e objetiva, sempre terão vantagem.



EXE: Dois anúncios praticamente idênticos, um com uma fonte diferente de outro, é possível saber qual deles atraiu mais *leads* apenas com a intuição?

1 Definição

A mineração de dados faz parte de um processo conhecido como *knowledge discovery in databases* (KDD) -extração não trivial de dados que permite a identificação de padrões válidos, úteis e inéditos-, portanto, é uma das etapas dentro de um mecanismo iterativo que vai desde a extração de dados crus até a formação de novos conhecimentos:

- limpeza: dados irrelevantes/ruídos removidos (valores em branco, valores viciados, variáveis duplicadas)
- Integração: diversas fontes de dados são combinadas em uma única fonte
- seleção: os dados considerados relevantes para a análise em questão são separados
- transformação: dados selecionados são transformados para o formato apropriado para o procedimento de mineração
- **mineração:** aplicação de técnicas (algoritmos) para extrair informações e/ou padrões que possuem potencial de uso


- avaliação de padrões: por meio de uso de métricas, padrões mais interessantes/pertinentes são identificados.
- criação de conhecimento: obtidos os padrões/informações, análises e representações gráficas são feitas para o usuário final.



A mineração de dados pode ter diferentes definições dependendo do autor e do campo de atuação, porém pode ser resumida como: **uma etapa fundamental no processo de criação de conhecimento que consiste na aplicação de algoritmos e na análise de dados a fim de encontrar padrões e gerar representações gráficas** que auxiliem na tomada de decisões.

Existem diversos modelos que padronizam as atividades executadas durante a mineração de dados. Apesar das particularidades, todos seguem uma mesma estrutura. O modelo mais conhecido e utilizado (padrão de maior aceitação) é


chamado de CRISP-DM (cross industry standard Process os Data Mining) e é composto por 6 fases organizadas de maneira cíclicas (fluxo não é unidirecional, podendo ir e voltar entre as fases)::



2 Fonte de dados

Dependendo da fonte de dados utilizada, as abordagens e algoritmos de mineração podem variar. Existem diversos tipos de fonte de dados: flat files, bancos de dados e suas variedades, armazém de dados e a web (a qual será o foco deste trabalho)

- **World Wide Web:** a web é o repositório mais abundante, heterogêneo e dinâmico disponível (alguns exemplos de documentos: texto, áudio, vídeo, APIs). Conceitualmente, é feita de 3 componentes: conteúdo (documentos que estão disponíveis), estrutura (hiperlinks e relação entre documentos), uso (como e quando os documentos são acessados). A mineração de dados na web, chamada de web mining, tenta cobrir todos os 3 componentes e é dividida em web content mining, web structure mining e web usage mining.



Category	Techniques	Tools	Algorithms
Web content mining	- Unstructured data mining - Structured data mining - Semi—structure data mining - Multimedia data mining	- Screen Scaper - Mozenda - Automation anywhere7 - Web content extractor - Web Info extractor - rapid miner	- Decision tree - Naive Bayes - Support vector machine - Neural network
Web structure mining	- Link-based Classification. - Link-based cluster analysis - Link type - Link strength - Link cardinality	- Google PR checker - link viewer	- Page rank - HITS algorithms (Hyperlink induced topic search) - Weighted Page Rank Algorithm - Distance Rank - Weighted page content rank - Webpage ranking using link attributes - Eigen rumor - Time rank Algorithm -tag Rank - Query dependent ranking
Web usage mining	- Data preprocessing - Pattern discovery - Pattern analysis	- Data preprocessing - Pattern discovery - Pattern analysis	- Association rules - Clustering - Classification - Sequential patterns

3 Tarefas

4 Métodos

5 Web mining

Já o *Data Mining* no contexto de *Web Mining* envolve a utilização de algum autômato/bot, geralmente um *crawler*, que possa extrair dados não estruturados de algum site ou *webpage*. Ao copiar e colar dados de um site, pode-se dizer que você está realizando um processo de *Web Scraping* - Extração de dados de uma dada página, quase como um *Text Mining* - manual.

No sentido empresarial, utiliza-se algoritmos/programas de *Web Scraping* que acessam o código fonte (HTML) dos sites e de lá extraem informações úteis para alguma tarefa ou negócio como um todo.

Usos mais relevantes:

- **Monitoramento de E-commerce:** *Web scraping* para monitoramento de sites de e-commerce a fim de agregar métricas de vendas relevantes;
- **Market Research:** Coleta de dados para a geração de *Business Intelligence* (BI) e também análise de *stocks* e financeira em geral;
- **Monitoramento de Notícias e Análise de sentimentos:** *Web scrapers* podem extrair fontes públicas e mídias sociais para o monitoramento de notícias e de *vibes*;
- **Treino de ChatBots:** Apesar de, hoje em dia, as empresas de IA evitarem utilizar o termo “*Web Scrapping*” para se referir a como coletaram os dados de treino de seus modelos, isso não deixa de ser uma das formas de obtenção de dados.

Vale ressaltar o aspecto ético de tal tecnologia, existe, portanto, bastante fricção sobre a suposta legalidade desses procedimentos. Mas, desde que você respeite os termos de serviço do site de coleta, em geral, não é considerado errado. Contudo, a coisa fica um pouco mais complicada com o advento da IA generativa, que necessita de grandes quantidades de dados para o seu treino.

Desde o advento de ChatBots generativos como os da Open AI até modelos de arte artificial como o Midjourney, houve questões sobre a legalidade dessas tecnologias, ainda mais levando em conta como os dados foram obtidos. Um caso recente que tange este problema é o do Reddit contra a empresa Perplexity, onde o Reddit acusa esta empresa de utilizar dados ilegalmente coletados de seu site, por um terceiro, para o treino de modelos de IA.

Hoje em dia, essa tecnologia vem evoluindo. A maioria dos sites oferecem APIs que permitem o acesso a informações destas fontes e de fácil acesso, se demonstrando uma alternativa aos métodos tradicionais de *Web Scraping*.

6 SteamWorks Web API

Para a extração dos dados da Steam, além da biblioteca “BeautifulSoup” para a mineração direta dos dados, também se utilizou a API da SteamWorks, acessível por meio de um comando GET (aqui simulados utilizando a biblioteca “requests”).

Esta é uma WebAPI, ou seja, as requisições são feitas por meio de uma URL, por exemplo, a seguinte URL:

<https://store.steampowered.com/appreviews/413150?json=1&language=portuguese>

Corresponde a busca das reviews (appreviews) jogo “Stardew Valley” (413150), em formato json em português. Ao acessar este link por um navegador, poderíamos ver o resultado dessa pesquisa:

JSON	Raw Data	Headers
Save	Copy	Collapse All Expand All Filter JSON
success:	1	
▼ query_summary:		
num_reviews:	9	
review_score:	9	
review_score_desc:	"Overwhelmingly Positive"	
total_positive:	1926	
total_negative:	22	
total_reviews:	1948	
▼ reviews:		
▼ 0:		
recommendationid:	"206628707"	
▼ author:		
steamid:	"76561198324296157"	
num_games_owned:	50	
num_reviews:	18	
playtime_forever:	771	
playtime_last_two_weeks:	0	
playtime_at_review:	602	
last_played:	1760533537	
language:	"portuguese"	
review:	"fiquei surpeendido , é bom para passar o tempo casual , só o preço é que não é o mais ajustável mas pronto tudo okay"	
timestamp_created:	1760358139	
timestamp_updated:	1760358139	

Fonte: Recurso de leitura de JSON do Firefox.

Ou seja, os dados são expostos em uma estrutura JSON que pode ser acessada por meio de um comando web “GET”. Neste caso esse comando web foi feito por meio da biblioteca “requests”, que além de emular o comando também formata o resultado JSON em um dicionário Python.

7 Fontes

- <https://s3.amazonaws.com/educa/pucrs/Aula/1683/Fabiano+Castello+-+Aula+01+e+02.pdf>
- https://ww2.inf.ufg.br/sites/default/files/uploads/relatorios-tecnicos/RT-INF_001-09.pdf
- <https://webdocs.cs.ualberta.ca/~zaiane/courses/cmput690/notes/Chapter1/ch1.pdf>
- <https://periodicos.udesc.br/index.php/reavi/article/download/5806/4206/0>
- https://thesai.org/Downloads/Volume9No6/Paper_30-Data_Mining_Web_Data_Mining_Techniques.pdf
- <https://www.pcmag.com/explainers/what-is-web-scraping-a-beginners-guide-to-data-extraction#>
- <https://www.cnbc.com/2025/10/23/reddit-user-data-battle-ai-industry-sues-perplexity-scraping-posts-openai-chatgpt-google-gemini-lawsuit.html#:~:text=Reddit%20alleged%20that%20AI%20company%20Perplexity%20accessed,over%20its%20user%20data%20through%20licensing%20agreements.>
- <https://cyberscoop.com/openai-lawsuit-privacy-data-scraping/>
- <https://www.browserless.io/blog/web-scraping-vs-data>
- <https://medium.com/image-processing-with-python/web-mining-196e47decb6a>
- <https://partner.steamgames.com/doc/api>
- <https://partner.steamgames.com/doc/store/getreviews>

índices do conteúdo daqui para baixo (apenas organização):

- algoritmo genético: definição, tipos
- análise de sentimentos: definição, métodos
- naive bayes (algoritmo base)
- apresentação do nosso algoritmo (naive bayes para classificação e ga para otimização)

NAIVE BAYES

O algoritmo Naive Bayes é um algoritmo de classificação supervisionado, probabilístico e baseado em conjuntos. É um dos principais utilizados em classificação por ser um dos mais eficazes e mais rápidos. Ele se baseia no teorema de Thomas Bayes (1702 - 1761), que calcula a probabilidade de um evento A, considerando evidências de B — a probabilidade condicional.

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

O nome Naive Bayes, além de Thomas Bayes, vem de ingênuo em inglês. O nome se dá pelo algoritmo tomar como premissa a independência condicional das características dos dados, o que é meio “ingênuo”, mas facilita os cálculos, pois, ao invés de calcular o teorema de bayes, propriamente, ele simplifica a relação dos conjuntos de forma

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i | y),$$

Em termos de classificação, o algoritmo calcula a probabilidade de uma amostra x fazer parte de uma classe A, considerando que ela já pertence à classe B. Se tomarmos como exemplo o conjunto estudado, o algoritmo vai calcular a probabilidade de uma *review* ser positiva e a probabilidade de ela ser negativa, e a que tiver maior probabilidade será a classe considerada.

Seja POS o conjunto de dados positivos e NEG o conjunto de dados negativos, o modelo começa selecionando todas as frases de ambos os conjuntos, calculando POS/NEG. É importante destacar que, mesmo que uma palavra seja considerada semanticamente negativa, por exemplo “ruim”, se a palavra foi encontrada em uma *review* categorizada como positiva, ela irá compor o conjunto positivo.

- POS = {muito, bom, emocionante, divertido, interessante, chato, superestimado, ruim, jogo}

- NEG = {bom, bom, emocionante, divertido, interessante, chato, superestimado, ruim, entediante, jogo}
- POSUNEG = {bom, emocionante, divertido, interessante, chato, superestimado, ruim, entediante, eu, nossa, jogo}

Em seguida, o modelo calcula a probabilidade inicial de cada conjunto.

$$P(A) = \sum x \in A / \sum y \in A \cup B$$

$$P(\text{POS}) = 9/11$$

$$P(\text{NEG}) = 8/11$$

Após isso, para cada elemento de POSUNEG, ele faz a contagem de quantas vezes o elemento aparece em cada conjunto.

$$a(x | A) = \text{aparições de } x \text{ em } A$$

POS

$$a(\text{muito} | \text{POS}) = 3$$

$$a(\text{bom} | \text{POS}) = 7$$

$$a(\text{emocionante} | \text{POS}) = 11$$

$$a(\text{divertido} | \text{POS}) = 7$$

$$a(\text{interessante} | \text{POS}) = 8$$

$$a(\text{chato} | \text{POS}) = 1$$

$$a(\text{superestimado} | \text{POS}) = 2$$

$$a(\text{ruim} | \text{POS}) = 1$$

$$a(\text{entediante} | \text{POS}) = 0$$

$$a(\text{eu} | \text{POS}) = 0$$

$$a(\text{nossa} | \text{POS}) = 0$$

$$a(\text{jogo} | \text{POS}) = 9$$

NEG

$$a(\text{muito} | \text{NEG}) = 4$$

$$a(\text{bom} | \text{NEG}) = 1$$

$$a(\text{emocionante} | \text{NEG}) = 2$$

$$a(\text{divertido} | \text{NEG}) = 0$$

$$a(\text{interessante} | \text{NEG}) = 1$$

$$a(\text{chato} | \text{NEG}) = 6$$

$$a(\text{superestimado} | \text{NEG}) = 5$$

$$a(\text{ruim} | \text{NEG}) = 9$$

$$a(\text{entediante} | \text{NEG}) = 6$$

$$a(\text{eu} | \text{NEG}) = 0$$

$$a(\text{nossa} | \text{NEG}) = 0$$

$$a(\text{jogo} \mid \text{NEG}) = 11$$

E então é calculado a probabilidade de cada palavra em cada conjunto:

$$p(x \mid A) = a(x \mid A)/N_A, \text{ sendo } N_A = \sum a(y) \in A$$

POS

$$\begin{aligned} P(\text{muito} \mid \text{POS}) &= 3/35 \\ P(\text{bom} \mid \text{POS}) &= 7/35 \\ P(\text{emocionante} \mid \text{POS}) &= 11/35 \\ P(\text{divertido} \mid \text{POS}) &= 7/35 \\ P(\text{interessante} \mid \text{POS}) &= 8/35 \\ P(\text{chato} \mid \text{POS}) &= 1/35 \\ P(\text{superestimado} \mid \text{POS}) &= 2/35 \\ P(\text{ruim} \mid \text{POS}) &= 1/35 \\ P(\text{entediante} \mid \text{POS}) &= 0/35 \\ P(\text{jogo} \mid \text{POS}) &= 9/35 \end{aligned}$$

NEG

$$\begin{aligned} P(\text{muito} \mid \text{NEG}) &= 4/30 \\ P(\text{bom} \mid \text{NEG}) &= 1/30 \\ P(\text{emocionante} \mid \text{NEG}) &= 2/30 \\ P(\text{divertido} \mid \text{NEG}) &= 0/30 \\ P(\text{interessante} \mid \text{NEG}) &= 1/30 \\ P(\text{chato} \mid \text{NEG}) &= 6/30 \\ P(\text{ruim} \mid \text{NEG}) &= 9/30 \\ P(\text{entediante} \mid \text{NEG}) &= 6/30 \\ P(\text{jogo} \mid \text{NEG}) &= 11/30 \end{aligned}$$

Esse é o processo de treinamento do modelo. A partir daqui, é possível calcular a probabilidade de novos dados pertencerem a um dos conjuntos, a partir do teorema de Bayes, fazendo a classificação dessas entradas.

Digamos que o modelo receba $r = \text{"esse jogo é muito bom"}$, o modelo irá calcular $p(r \mid \text{POS})$ e $p(r \mid \text{NEG})$. Claro que, antes, é feito o tratamento dos dados, removendo as *stop words*, obtendo $r' = \text{"jogo muito bom"}$.

$$\begin{aligned} P(r \mid \text{POS}) &= p(\text{POS}) * P(\text{"jogo"} \mid \text{POS}) * P(\text{"muito"} \mid \text{POS}) * P(\text{"bom"} \mid \text{POS}) \\ P(r \mid \text{NEG}) &= p(\text{NEG}) * P(\text{"jogo"} \mid \text{NEG}) * P(\text{"muito"} \mid \text{NEG}) * P(\text{"bom"} \mid \text{NEG}) \end{aligned}$$

substituindo os valores...

$$\begin{aligned} \rightarrow P(r \mid \text{POS}) &= 9/11 * 9/35 * 7/35 = 0.04 \\ \rightarrow P(r \mid \text{NEG}) &= 8/11 * 11/30 * 1/30 = 0.008... \end{aligned}$$

$P(r \mid \text{POS}) > P(r \mid \text{NEG})$, portanto r é classificada pelo modelo como uma *review* positiva.

É interessante observar que o algoritmo será sempre o mesmo, porém ele utiliza probabilidades únicas dos dados utilizados no treinamento. Dessa forma, o modelo é capaz de perceber detalhes intrínsecos de cada conjunto, como: quando a palavra “muito” aparece anterior a uma palavra categorizada como positiva, como “bom”, o viés para ele ser classificado como positivo será grande, por conta do peso carregado pela palavra.

A respeito da ingenuidade do algoritmo, vejamos o que acontece se o modelo receber uma *review* $q = \text{“eu amei esse jogo”}$. Removendo as *stop words*, obtemos $q' = \text{“eu amei jogo”}$. Ao calcular sua probabilidade nas classes, temos $P(q' \mid \text{POS}) = 0$ e $P(q' \mid \text{NEG}) = 0$, pois $P(\text{eu})$ em ambas as classes é 0 e, ao ser multiplicado por outras probabilidades, acaba zerando tudo. A ingenuidade do modelo considerar a independência de cada característica dos dados faz com que ele desconsidere a presença ou ausência de certas palavras em outras *reviews*. Para contornar isso, é comum modelar o algoritmo de forma que ele calcule $P(x \mid A)$ como $P(x + 1 \mid A)$, $\forall x \in A$, o que não muda as predições finais e evita que dados sem peso algum anule as demais probabilidades — isso já é feito em modelos como os da biblioteca *scikit-learn*.

Por se tratar de uma classificação probabilística, o algoritmo considera diferentes distribuições para os dados, existindo 3 tipos distintos do algoritmo. A utilizada no modelo exemplificado acima é a multinomial.

- Multinomial: utilizada para classificação de dados quantitativos discretos;
- Gaussiana: utilizada para classificação de dados quantitativos contínuos;
- Bernoulli: utilizada para classificação de dados binários.

ALGORITMO GENÉTICO

1 Definição


A busca heurística é uma técnica usada para otimizar soluções em problemas complexos, principalmente quando o espaço de estados é muito grande. Quando não é possível explorar todas as alternativas, ela se torna uma boa opção. O valor heurístico usado pode ser qualquer valor subjetivo.

Pense em um labirinto, onde cada posição representa um estado possível. Nesse caso, a busca heurística ajuda a escolher os caminhos mais promissores, atribuindo valores com base em critérios como proximidade e eficiência.

Em resumo, é um método baseado em valores heurísticos que não garante a melhor solução, mas é eficaz o bastante para encontrar resultados aceitáveis em um tempo razoável.

2 Tipos de Busca Heurística

A busca heurística pode ser dividida em dois tipos principais, sendo eles: busca gulosa (Greedy Search) e busca A* (A-Star ou A-Estrela).



A busca gulosa usa como base apenas a função heurística, representada por $f(n) = h(n)$, onde $h(n)$ é a estimativa do custo do caminho até o objetivo, sendo que $h(n) = 0$ se n for o estado meta. Normalmente, a função $h(n)$ é construída de forma específica para cada problema.

Esse tipo de busca escolhe o caminho que parece mais próximo do objetivo, olhando apenas para o valor heurístico ($h(n)$). Ela tenta chegar rápido ao destino, sem considerar o custo do caminho já percorrido ($g(n)$). É mais simples e rápida, mas pode acabar pegando um caminho ruim e não encontrar a melhor solução.

Já a busca A* considera tanto o custo do caminho percorrido quanto a estimativa até o objetivo, usando a função $f(n) = g(n) + h(n)$, onde $g(n)$ representa o custo acumulado do caminho atual e $h(n)$ a estimativa de custo até o objetivo.

Com isso, a busca A* busca um equilíbrio entre o custo já percorrido ($g(n)$) e o que ainda falta percorrer ($h(n)$). Dessa forma, ela normalmente encontra a solução

ótima, desde que a heurística usada seja admissível, ou seja, que não superestime o custo até o objetivo.

Ou seja, a Busca Gulosa: $f(n) = h(n)$, é mais rápida, mas pode falhar em achar a melhor rota, enquanto à Busca A*: $f(n) = g(n) + h(n)$, é mais precisa e tende a encontrar a solução ótima.

3 Análise de Sentimentos

Quando se trata de uma análise de sentimentos com dados textuais, a busca A* normalmente seria a melhor opção e isso se deve pois, a busca gulosa tende a olhar apenas para o que “parece” mais promissor naquele momento, ou seja, ela seguiria as palavras ou expressões que mais indicam um sentimento positivo ou negativo de forma imediata, sem levar em conta o contexto geral de uma frase. Isso pode causar erros, visto que em linguagem natural o sentido real de uma frase depende da estrutura completa e da relação entre as palavras.

Por exemplo, em “o filme parecia bom, mas o final foi decepcionante”, a palavra “bom” isolada dá uma impressão positiva, mas o sentimento global é negativo. A busca gulosa provavelmente se deixaria enganar por esse trecho inicial, porquê ela só olha para o valor heurístico local.

Enquanto isso, a busca A* leva em conta tanto o que já foi analisado ($g(n)$, o custo acumulado, que representa o contexto das palavras anteriores) quanto o que ainda falta interpretar ($h(n)$, a estimativa até o fim da frase). Isso faz com que ela mantenha uma noção de contexto ao longo da análise, equilibrando as partes locais e o sentido global.

4 Fonte de dados

<https://medium.com/@gabrielluizone/descobrimos-a-eficácia-da-busca-heurística-0772a5fae145>

<https://www.ime.usp.br/~leliane/IAcurso2006/slides/Aula5-Astar-2006>

 COMO FAZER ANÁLISE DE SENTIMENTOS COM DADOS TEXTUAIS

5 Tarefas

6 Métodos